

Ficha Técnica: Projeto de Análise de Dados SuperStore

Título do Projeto: Otimização Operacional e Diagnóstico de Rentabilidade Logística da SuperStore.

Objetivo: O objetivo principal deste projeto é construir uma camada analítica robusta para a SuperStore para avaliar o impacto real das estratégias de desconto na margem de lucro, reduzir incertezas logísticas ao identificar os modos de envio mais rentáveis e detectar sinais precoces de prejuízo operacional. O estudo visa substituir decisões baseadas em intuição e falta de padronização por recomendações estratégicas fundamentadas em dados.

Equipe: Analista de Dados - Cintia Alves

Ferramentas e Tecnologias: Google BigQuery (SQL), Google Sheets, Looker Studio, Claude e Gemini (Agente de IA / Gems)

Contexto

O conjunto de dados simula as operações de varejo global da potência SuperStore. Ele é composto por duas tabelas principais estruturadas no BigQuery:

- **Tabela de Pedidos (Order):** Contém originalmente **19.961 linhas** e 15 variáveis principais (order_id, category, city, country, customer_id, customer_name, discount, order_priority, product_id, product_name, profit, quantity, sales, segment, order_date).
- **Tabela de Envios (Shipping):** Contém dados complementares de logística, trazendo 5 variáveis chaves (order_id, product_id, ship_date, ship_mode, shipping_cost).

Nota: O campo order_id não é exclusivo, pois um pedido pode conter múltiplos itens. A chave primária para cruzamento é uma chave composta formada por order_id e product_id.

Processamento e Análises

O processo de limpeza, transformação e análise exploratória foi executado em etapas estruturadas no BigQuery utilizando comandos SQL:

1. Identificação e Tratamento de Valores Nulos

- Foi realizada uma contagem de nulos em todas as colunas com a fórmula completa COUNTIF(Sales IS NULL).

- Identificou-se **22 registros** com valores nulos exclusivamente na coluna Sales.
- **Decisão de Negócio:** Investigou-se se os nulos estavam concentrados por país ou modal de frete e concluiu-se que estavam espalhados aleatoriamente (erro de exportação do sistema). Como os campos cruciais como quantidade (quantity) e lucro (profit) estavam preenchidos normalmente, optou-se por **manter os registros**, desconsiderando-os automaticamente apenas nas métricas de receita total, evitando distorções artificiais.

2. Identificação e Eliminação de Duplicados

- Utilizou-se agrupamento com GROUP BY order_id, product_id HAVING COUNT(*) > 1 para localizar duplicatas. Foram encontradas **32 linhas duplicadas** no total (16 em cada tabela).
- **Investigação:** Na tabela Order, as linhas eram 100% idênticas (erro de sistema). Na tabela Shipping, constatou-se registros com modos de envio diferentes para o mesmo item (erros operacionais ou reentregas).
- **Decisão de Negócio:** Para limpar a base sem perder histórico, foi gerada uma nova tabela chamada Csv_limpa usando a função de janela ROW_NUMBER() OVER (PARTITION BY order_id, product_id ORDER BY order_id) AS row_num e filtrando apenas onde row_num = 1.

3. Validação de Variáveis Categóricas

- Rodou-se consultas com GROUP BY para mapear os valores únicos das colunas textuais. Os dados mostraram-se perfeitamente padronizados em **3 Categorias** (*Furniture, Office Supplies, Technology*), **3 Segmentos** (*Consumer, Corporate, Home Office*) e **4 Modos de Envio** (*First Class, Same Day, Second Class, Standard Class*). Não houve necessidade de aplicar correções com CASE WHEN.

4. Correção de Inconsistências Numéricas (Outliers no Lucro)

- Ao rodar as funções agregadas MIN, MAX e AVG, o BigQuery apontou lucros discrepantes na casa dos milhões devido ao campo profit estar originalmente configurado como texto (STRING) e usando pontos como separadores de milhar.
- **Ajuste Técnico:** A coluna profit apresenta valores extremos decorrentes de um problema de formatação numérica durante a importação. Os valores foram identificados, tratados e escalados dividindo-se o valor convertido por 1000 para readequar a métrica ao comportamento real por meio da instrução completa CAST(REPLACE(CAST(profit AS STRING), ',', '.')) AS FLOAT64) / 1000 AS profit.

5. União das Tabelas (SQL JOIN)

- Para unificar a camada de vendas à camada logística, executou-se um LEFT JOIN unindo as tabelas tratadas de pedidos e envios usando a chave composta obrigatória:

FROM superstoreorder.Csv_limpa o LEFT JOIN superstoreshipping.Csv_limpa s
ON o.order_id = s.order_id AND o.product_id = s.product_id. O resultado
consolidado foi salvo na tabela definitiva Csv_final.

Resultados e Conclusões

Com o suporte analítico do Agente de IA (Gem) focado em negócios, os dados limpos revelaram um diagnóstico crítico sobre a saúde financeira da categoria de Móveis (*Furniture*):

- **A Crise Crônica de Rentabilidade em Móveis:** A análise temporal revelou que, enquanto as categorias de *Technology* e *Office Supplies* operam de forma saudável e consistentemente no campo positivo, a linha de lucro de *Furniture* (Móveis) passa a maior parte do histórico acumulado afundada no prejuízo (abaixo da linha zero).
- **O Vilão Oculto – A Modalidade *Second Class*:** Ao isolar o lucro de móveis por tipo de logística, quebrou-se o mito de que o prejuízo era causado por fretes urgentes e expressos (como *Same Day* ou *First Class*, que operam em patamar neutro). O ralo financeiro real está concentrado na modalidade **Second Class**, que registrou a maior barra de prejuízo isolado (atingindo a marca proporcional de **-1.40** no eixo do estudo).
- **Diagnóstico Operacional:** A *Second Class* representa um meio-termo altamente ineficiente para produtos pesados e volumosos. As transportadoras cobram caro da SuperStore para acelerar o envio desse tipo de produto, porém a empresa não consegue repassar comercialmente essa taxa logística de forma justa para o cliente final. Em termos práticos, a SuperStore está absorvendo integralmente os custos elevados de cubagem e velocidade de itens de grande porte, permitindo que uma única modalidade destrua as margens do negócio.

Recomendações Estratégicas para a Diretoria:

1. **Bloqueio Imediato da Modalidade:** Suspender por tempo determinado a opção de envio *Second Class* para qualquer produto volumoso da categoria de Móveis (*Furniture*) nos mercados que apresentam o problema.

2. **Repassse Obrigatório de Custos (Cubagem):** Alterar as regras do site para forçar o comprador de móveis a escolher estritamente entre o frete econômico (*Standard Class*) — aceitando prazos de entrega maiores — ou arcar integralmente com a taxa real repassada de uma entrega expressa (*First Class*).

Limitações / Próximos Passos

Limitações dos Dados:

- **Efeito de Escala Modificada:** Devido ao tratamento matemático e estatístico necessário para neutralizar as anomalias originais de bilhões de dólares no campo profit, as análises atuais avaliam direções de perdas e proporções perfeitamente validadas, mas não exibem os valores financeiros absolutos exatos em moeda corrente (ex: milhares de dólares).
- **Ausência de Variáveis Físicas e Logísticas cruciais:** A base de dados atual não registra o peso real das mercadorias ou o volume em metros cúbicos ($\text{\$m}^3$) dos produtos vendidos. Isso impede que a equipe analítica recalcule com precisão matemática a tabela de precificação ideal de frete para cada tipologia de móvel.

Próximos Passos:

- **Enriquecimento da Base de Dados:** Solicitar ao departamento de engenharia de produto a integração das variáveis de peso, cubagem e dimensões das mercadorias na tabela de pedidos.
- **Simulação de Impacto Financeiro:** Avaliar através de uma pergunta crítica reflexiva para a liderança: "*Se removermos o frete intermediário (Second Class), qual a proporção de clientes de Móveis migrará para o frete Standard versus o cancelamento de pedidos?*". Isso permitirá prever a elasticidade da demanda antes de uma alteração definitiva na política de fretes da companhia.